Лабораторная работа №4
Линейная регрессия

Датасет `AirQualityUCI`, содержит информацию о различных метеорологических показателях и уровнях загрязнения воздуха в одном из итальянских городов.

В датасете представлены следующие признаки:

1. Дата - дата измерения информации.
2. Время - время измерения информации.
3. CO(GT) - уровень концентрации оксида углерода в мг/м³ (целевая переменная).
4. PT08.S1(CO) - уровень концентрации оксида олова в мкг/м³.
5. NMHC(GT) - уровень общих неуглеводородных компонентов в мкг/м³.
6. C6H6(GT) - уровень концентрации бензола в мкг/м³.
7. PT08.S2(NMHC) - уровень концентрации оксидов азота в мкг/м³.
8. NOx(GT) - уровень концентрации оксидов азота в ппб (частей на миллиард).
9. PT08.S3(NOx) - уровень концентрации осиных оксидов в мкг/м³.
10. NO2(GT) - уровень концентрации диоксида азота в мкг/м³.
11. PT08.S4(NO2) - уровень концентрации оксидов углерода в мкг/м³.
12. PT08.S5(O3) - уровень концентрации озона в мкг/м³.
13. T - температура в °C.
14. RH - относительная влажность в %.
15. AH - высота водяного пара в г/м³.

1. **Базовая линейная регрессия с одним признаком.** Предсказать уровень концентрации оксида углерода (`CO(GT)`) на основе уровня концентрации бензола (`C6H6(GT)`) используя простую линейную регрессию. Использовать метрики: R-квадрат, MSE.

2. **Множественная линейная регрессия.** Предсказать уровень концентрации оксида углерода (`CO(GT)`) на основе нескольких признаков (например, `C6H6(GT)`, `T`, `RH`, `NO2(GT)`). Использовать метрики: R-квадрат, MSE.

3. **Стандартизация признаков и линейная регрессия.** Повторить задачу 2, но перед обучением модели стандартизировать признаки, используя `StandardScaler`. Использовать метрики: R-квадрат, MSE.

4. **Линейная регрессия с L1 регуляризацией (Lasso).** Предсказать уровень концентрации оксида углерода (`CO(GT)`) на основе всех доступных признаков, используя линейную регрессию с L1 регуляризацией (Lasso). Подобрать оптимальный параметр регуляризации (alpha) с помощью кросс-валидации. Использовать метрики: R-квадрат, MSE, также оценить количество ненулевых коэффициентов.

5. **Линейная регрессия с L2 регуляризацией (Ridge).** Предсказать уровень концентрации оксида углерода (`CO(GT)`) на основе всех доступных признаков, используя линейную регрессию с L2 регуляризацией (Ridge). Подобрать оптимальный параметр регуляризации (alpha) с помощью кросс-валидации. Использовать метрики: R-квадрат, MSE.

6. **Кросс-валидация для оценки модели.** Использовать K-fold кросс-валидацию (например, с K=5 или K=10) для оценки производительности модели множественной линейной регрессии (пункт 2). Использовать метрики: R-квадрат, MSE по всем фолдам.

7. **Регуляризация с кросс-валидацией для выбора параметра alpha (Lasso или Ridge).** Использовать кросс-валидацию для выбора оптимального значения параметра регуляризации alpha для Lasso или Ridge регрессии. Например, использовать `RidgeCV` или `LassoCV` из scikit-learn. Использовать метрики: R-квадрат, MSE, оптимальное значение alpha.

8. **Полиномиальная регрессия.** Создать полиномиальные признаки (например, до степени 2 или 3) из исходных признаков и использовать их для обучения линейной регрессии. Сравнить производительность с обычной линейной регрессией. Использовать метрики: R-квадрат, MSE.

9. **Сравнение моделей и интерпретация результатов.** Сравнить производительность всех построенных моделей (простая линейная регрессия, множественная линейная регрессия, Lasso, Ridge, полиномиальная регрессия). Проанализировать коэффициенты моделей и сделать выводы о важности различных признаков для прогнозирования `CO(GT)`.